

# Организация данных Физическая структура



## **Авторские права**

© Postgres Professional, 2017–2021

Авторы: Егор Рогов, Павел Лузанов

## **Использование материалов курса**

Некоммерческое использование материалов курса (презентации, демонстрации) разрешается без ограничений. Коммерческое использование возможно только с письменного разрешения компании Postgres Professional. Запрещается внесение изменений в материалы курса.

## **Обратная связь**

Отзывы, замечания и предложения направляйте по адресу:

[edu@postgrespro.ru](mailto:edu@postgrespro.ru)

## **Отказ от ответственности**

Компания Postgres Professional не несет никакой ответственности за любые повреждения и убытки, включая потерю дохода, нанесенные прямым или косвенным, специальным или случайным использованием материалов курса. Компания Postgres Professional не предоставляет каких-либо гарантий на материалы курса. Материалы курса предоставляются на основе принципа «как есть» и компания Postgres Professional не обязана предоставлять сопровождение, поддержку, обновления, расширения и изменения.


Табличные пространства и каталоги

Файлы и страницы данных

Слои: данные, карты видимости и свободного пространства

Технология TOAST

# Табличные пространства



3

Табличные пространства (ТП) служат для организации физического хранения данных и определяют расположение данных в файловой системе.


Например, можно создать одно табличное пространство на медленных дисках для архивных данных, а другое – на быстрых дисках для данных, с которыми идет активная работа.

При инициализации кластера создаются два табличных пространства: `pg_default` и `pg_global`.

Одно и то же табличное пространство может использоваться разными базами данных, а одна база данных может хранить данные в нескольких табличных пространствах.

При этом у каждой БД есть так называемое «табличное пространство по умолчанию», в котором создаются все объекты, если явно не указать иное. В этом же табличном пространстве хранятся и объекты системного каталога. Изначально в качестве «табличного пространства по умолчанию» используется `pg_default`, но можно установить и другое.

Табличное пространство `pg_global` особенное: в нем хранятся те объекты системного каталога, которые являются общими для кластера.



По сути, табличное пространство — это указание на каталог, в котором располагаются данные. Стандартные табличные пространства `pg_global` и `pg_default` всегда находятся в `PGDATA/global/` и `PGDATA/base/` соответственно.

При создании пользовательского табличного пространства указывается произвольный каталог. Сервер всегда использует относительные пути, поэтому на указанный каталог дополнительно создается символическая ссылка в каталоге `PGDATA/pg_tblspc/`.

Внутри каталога `PGDATA/base/` данные дополнительно разложены по подкаталогам баз данных (для `PGDATA.global/` это не требуется, так как данные в нем относятся к кластеру в целом).

Внутри каталога пользовательского табличного пространства появляется еще один уровень вложенности: подкаталог для версии сервера PostgreSQL. Это сделано для удобства обновления сервера на другую версию.

Сами объекты хранятся в файлах внутри этих каталогов. У каждого объекта собственный набор файлов: в одном файле находятся данные только одного объекта

Каждый файл, называемый *сегментом*, занимает по умолчанию не более 1 Гбайт (этот размер можно изменить при сборке сервера). Поэтому каждому объекту может соответствовать несколько файлов. Необходимо учитывать влияние потенциально большого количества файлов на используемую файловую систему.

<https://postgrespro.ru/docs/postgresql/12/storage-file-layout>

## Использование табличных пространств

Изначально в кластере присутствуют два табличных пространства. Информация о них содержится в системном каталоге:

```
=> SELECT spcname FROM pg_tablespace;
```

```
   spcname
-----
pg_default
pg_global
(2 rows)
```

Конечно, это одна из глобальных для всего кластера таблиц.

Аналогичная команда psql:

```
=> \db
```

```
      List of tablespaces
   Name   | Owner   | Location
-----+-----+-----
pg_default | postgres |
pg_global  | postgres |
(2 rows)
```

Чтобы создать новое табличное пространство, надо подготовить пустой каталог, владельцем которого является пользователь, запускающий сервер СУБД (команда выполняется от имени postgres):

```
postgres$ mkdir /var/lib/postgresql/ts_dir
```

Теперь выполняем команду, указывая каталог:

```
=> CREATE TABLESPACE ts LOCATION '/var/lib/postgresql/ts_dir';
```

```
CREATE TABLESPACE
```

```
=> \db
```

```
      List of tablespaces
   Name   | Owner   | Location
-----+-----+-----
pg_default | postgres |
pg_global  | postgres |
ts         | student  | /var/lib/postgresql/ts_dir
(3 rows)
```

При создании базы данных можно указать табличное пространство по умолчанию:

```
=> CREATE DATABASE data_physical TABLESPACE ts;
```

```
CREATE DATABASE
```

```
=> \c data_physical
```

You are now connected to database "data\_physical" as user "student".

Это означает, что все объекты будут создаваться именно в этом табличном пространстве, если другое не указано явно.

```
=> CREATE TABLE t(id integer PRIMARY KEY, s text);
```

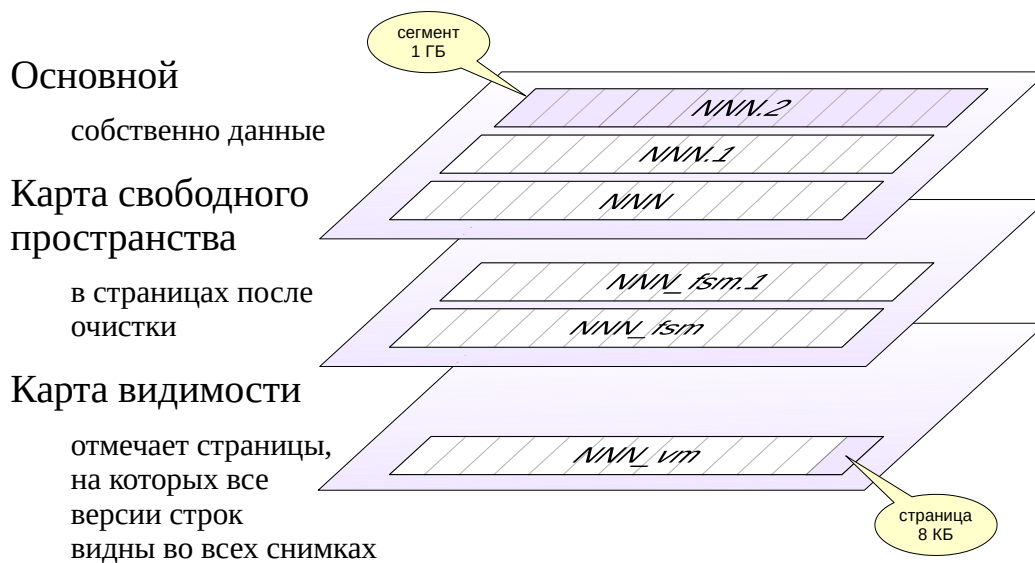
```
CREATE TABLE
```

```
=> INSERT INTO t(id, s)
    SELECT id, id::text FROM generate_series(1,100000) id;
```

```
INSERT 0 100000
```

```
=> VACUUM t;
```

```
VACUUM
```



Обычно каждому объекту соответствует несколько *слоев* (forks). Каждый слой — это набор *сегментов* (то есть файл или несколько файлов). Все файлы-сегменты разбиты на отдельные *страницы*, обычно по 8 Кбайт (размер можно установить для всего кластера только при сборке сервера). Страницы разных объектов считываются с диска совершенно однотипно через общий механизм буферного кеша.

**Основной слой** — это собственно данные: версии строк таблиц или строки индексов.

Слой *vm* (visibility map) — битовая **карта видимости**. В ней отмечены страницы, которые содержат только актуальные версии строк, видимые во всех снимках данных. Иными словами, это страницы, которые давно не изменялись и успели полностью очиститься от неактуальных версий.

Карта видимости применяется для оптимизации очистки (отмеченные страницы не нуждаются в очистке) и для ускорения индексного доступа. Дело в том, что информация о версионности хранится только для таблиц, но не для индексов (поэтому у индексов не бывает карты видимости). Получив из индекса ссылку на версию строки, нужно прочитать табличную страницу, чтобы проверить ее видимость. Но если в самом индексе уже есть все нужные столбцы, и при этом страница отмечена в карте видимости, то к таблице можно не обращаться.

Слой *fsm* (free space map) — **карта свободного пространства**. В ней отмечено доступное место внутри страниц, образующееся при очистке. Эта карта используется при вставке новых версий строк, чтобы быстро найти подходящую страницу.

## Слои и файлы

Узнать расположение файлов, относящихся к объекту, можно так:

```
=> SELECT pg_relation_filepath('t');

      pg_relation_filepath
-----
pg_tblspc/16411/PG_12_201909212/16412/16413
(1 row)
```

Посмотрим на сами файлы (имя и размер в байтах):

```
student$ sudo find /var/lib/postgresql/12/main/pg_tblspc/16411/PG_12_201909212/16412 -name 16413* -printf '%f\t%s\n'

16413_vm          8192
16413_fsm         24576
16413             4423680
```

Видно, что они относятся к трем слоям: основному, fsm и vm.

Объекты можно перемещать между табличными пространствами, но (в отличие от перемещения между схемами) это приводит к физическому переносу данных:

```
=> ALTER TABLE t SET TABLESPACE pg_default;
```

ALTER TABLE

```
=> SELECT pg_relation_filepath('t');

      pg_relation_filepath
-----
base/16412/16421
(1 row)
```

## Размер объектов

Узнать размер, занимаемый базой данных и объектами в ней, можно с помощью ряда функций.

```
=> SELECT pg_database_size('data_physical');

      pg_database_size
-----
14902127
(1 row)
```

Для упрощения восприятия можно вывести число в отформатированном виде:

```
=> SELECT pg_size_pretty(pg_database_size('data_physical'));

      pg_size_pretty
-----
14 MB
(1 row)
```

Полный размер таблицы (вместе со всеми индексами):

```
=> SELECT pg_size_pretty(pg_total_relation_size('t'));

      pg_size_pretty
-----
6568 kB
(1 row)
```

И отдельно размер таблицы...

```
=> SELECT pg_size_pretty(pg_table_size('t'));

      pg_size_pretty
-----
4360 kB
(1 row)
```

...и индексов:

```
=> SELECT pg_size_pretty(pg_indexes_size('t'));
```

```
pg_size_pretty
-----
2208 kB
(1 row)
```

При желании можно узнать и размер отдельных слоев таблицы, например:

```
=> SELECT pg_size_pretty(pg_relation_size('t','main'));
```

```
pg_size_pretty
-----
4320 kB
(1 row)
```

Размер табличного пространства показывает другая функция:

```
=> SELECT pg_size_pretty(pg_tablespace_size('ts'));
```

```
pg_size_pretty
-----
10209 kB
(1 row)
```



Версия строки должна помещаться на одну страницу

можно сжать часть атрибутов,  
или вынести в отдельную TOAST-таблицу,  
или сжать и вынести одновременно

TOAST-таблица

схема pg\_toast  
поддержана собственным индексом  
«длинные» атрибуты разделены на части размером меньше страницы  
читается только при обращении к «длинному» атрибуту  
собственная версия  
работает прозрачно для приложения

Любая версия строки в PostgreSQL должна целиком помещаться на одну страницу. Для «длинных» версий строк применяется технология TOAST — The Oversized Attributes Storage Technique. Она подразумевает несколько стратегий. Подходящий «длинный» атрибут может быть сжат так, чтобы версия строки поместилась на страницу. Если это не получается, атрибут может быть отправлен в отдельную служебную таблицу. Могут применяться и оба подхода.

Для каждой основной таблицы при необходимости создается отдельная toast-таблица (и к ней специальный индекс). Такие таблицы и индексы располагаются в отдельной схеме pg\_toast и поэтому обычно не видны.

Версии строк в toast-таблице тоже должны помещаться на одну страницу, поэтому «длинные» значения хранятся порезанными на части. Из этих частей PostgreSQL прозрачно для приложения «склеивает» необходимое значение.

Toast-таблица используется только при обращении к «длинному» значению. Кроме того, для toast-таблицы поддерживается своя версия: если обновление данных не затрагивает «длинное» значение, новая версия строки будет ссылаться на то же самое значение в toast-таблице. Это позволяет экономить место.

<https://postgrespro.ru/docs/postgresql/12/storage-toast>

## TOAST

Добавим в таблицу очень длинную строку:

```
=> INSERT INTO t(id, s)
SELECT 0, string_agg(id::text, '.') FROM generate_series(1,10000) AS id;
```

```
INSERT 0 1
```

```
=> VACUUM;
```

```
VACUUM
```

Изменится ли размер таблицы?

```
=> SELECT pg_size_pretty(pg_table_size('t'));
```

```
pg_size_pretty
-----
4440 kB
(1 row)
```

Да. А размер основного слоя, в котором хранятся данные?

```
=> SELECT pg_size_pretty(pg_relation_size('t','main'));
```

```
pg_size_pretty
-----
4320 kB
(1 row)
```

Нет.

Поскольку строка не помещается в одну страницу, значение атрибута s будет разрезано на части и помещено в отдельную toast-таблицу. Ее можно отыскать в системном каталоге (мы используем тип regclass, чтобы преобразовать oid в имя отношения):

```
=> SELECT reltoastrelid::regclass::text FROM pg_class WHERE relname='t';
```

```
reltoastrelid
-----
pg_toast.pg_toast_16413
(1 row)
```

Наша строка хранится по частям, из которых PostgreSQL при необходимости склеивает полное значение:

```
=> SELECT chunk_id, chunk_seq, left(chunk_data::text,45) AS chunk_data
FROM pg_toast.pg_toast_16413 LIMIT 5;
```

chunk_id	chunk_seq	chunk_data
16424	0	\xfdbe000000312e322e332e342e00352e362e372e382
16424	1	\x392e353161ff31002e3531322e353133002e3531342
16424	2	\xe215e216e217e218abe219e11a30e11b30e11c30e11
16424	3	\x11f4aa3611f43611f43611f43611f4aa3611f43611f
16424	4	\xf43211f4325511f43211f43211f43211f4325511f43

(5 rows)

В заключение удалим базу данных.

```
=> \c postgres
```

You are now connected to database "postgres" as user "student".

```
=> DROP DATABASE data_physical;
```

```
DROP DATABASE
```

После того, как в табличном пространстве не осталось объектов, можно удалить и его:

```
=> DROP TABLESPACE ts;
```

```
DROP TABLESPACE
```

## Физически

данные распределены по табличным пространствам (каталогам)

объект представлен несколькими слоями

каждый слой состоит из одного или нескольких файлов-сегментов

Табличными пространствами управляет администратор

Слои, файлы, TOAST — внутренняя кухня PostgreSQL

1. Создайте новую базу данных и подключитесь к ней.  
Создайте табличное пространство ts.  
Создайте таблицу t в табличном пространстве ts  
и добавьте в нее несколько строк.
2. Вычислите объем, занимаемый базой данных, таблицей  
и табличными пространствами ts и pg\_default.
3. Перенесите таблицу в табличное пространство pg\_default.  
Как изменился объем табличных пространств?
4. Удалите табличное пространство ts.

## 1. Табличные пространства и таблица

Создаем базу данных:

```
=> CREATE DATABASE data_physical;
```

```
CREATE DATABASE
```

```
=> \c data_physical
```

You are now connected to database "data\_physical" as user "student".

Табличное пространство:

```
postgres$ mkdir /var/lib/postgresql/ts_dir
```

```
=> CREATE TABLESPACE ts LOCATION '/var/lib/postgresql/ts_dir';
```

```
CREATE TABLESPACE
```

Создаем таблицу:

```
=> CREATE TABLE t(n integer) TABLESPACE ts;
```

```
CREATE TABLE
```

```
=> INSERT INTO t SELECT 1 FROM generate_series(1,1000);
```

```
INSERT 0 1000
```

## 2. Размер данных

Объем базы данных:

```
=> SELECT pg_size_pretty(pg_database_size('data_physical')) AS db_size;
```

```
db_size
-----
8041 kB
(1 row)
```

Размер таблицы:

```
=> SELECT pg_size_pretty(pg_total_relation_size('t')) AS t_size;
```

```
t_size
-----
64 kB
(1 row)
```

Объем табличных пространств:

```
=> SELECT
  pg_size_pretty(pg_tablespace_size('pg_default')) AS pg_default_size,
  pg_size_pretty(pg_tablespace_size('ts')) AS ts_size;
```

```
pg_default_size | ts_size
-----+-----
188 MB          | 68 kB
(1 row)
```

Размер табличного пространства несколько больше размера таблицы за счет служебных файлов, хранящихся в каталоге табличного пространства.

## 3. Перенос таблицы

Перенесем таблицу:

```
=> ALTER TABLE t SET TABLESPACE pg_default;
```

```
ALTER TABLE
```

Новый объем табличных пространств:

```
=> SELECT
  pg_size_pretty(pg_tablespace_size('pg_default')) AS pg_default_size,
  pg_size_pretty(pg_tablespace_size('ts')) AS ts_size;
```

pg_default_size	ts_size
188 MB	4096 bytes

(1 row)

#### 4. Удаление табличного пространства

Удаляем табличное пространство:

=> **DROP TABLESPACE** ts;

DROP TABLESPACE